



Centro de Investigación en Matemáticas, A.C.  
Optimización

## Proyecto. El método de región de confianza para funciones con ruido

José Miguel Saavedra Aguilar, Carlos Manuel Bosch Machado

---

### Resumen

En este proyecto se presenta el método de región de confianza para funciones con ruido. Este método asegura convergencia en probabilidad a una región crítica que contiene al óptimo. Para la implementación se utiliza el algoritmo **ECNoise** [2] para estimar el ruido, para obtener la dirección de descenso se utiliza la aproximación por Dogleg [3] y la actualización de la aproximación de la Hessiana utilizando BFGS.

## 1. Introducción

Recordemos el método de región de confianza clásico [3] para  $f(x)$ , en el cual buscamos la dirección que minimice el modelo

$$\begin{aligned} d_k = \arg \min_{d \in \mathbb{R}^n} \quad & m_k(d) := \frac{1}{2}d^\top B_k d + g_k^\top d + f(x_k) \\ \text{s.t.} \quad & \|d\| \leq \Delta_k \end{aligned} \tag{1}$$

Para  $g_k = \nabla f(x_k)$  y  $B_k$  una matriz SPD. Una vez elegida la dirección, se calcula la *medida de confianza*  $\rho$ :

$$\rho_k = \frac{f(x_k + d_k) - f(x_k)}{m_k(d_k) - m_k(0)}$$

Con base en el valor de  $\rho_k$  y dadas  $\eta_1 < \eta_2$ , y  $\lambda_1 < 1 < \lambda_2$  actualizamos el radio  $\Delta_k$  de la forma:

$$\Delta_{k+1} = \begin{cases} \lambda_1 \Delta_k & \rho_k < \eta_1 \\ \Delta_k & \rho_k \in [\eta_1, \eta_2] \\ \lambda_2 \Delta_k & \rho_k > \eta_2 \end{cases}$$

Finalmente, se actualiza  $x_k$  de la forma:

$$x_{k+1} = \begin{cases} x_k & \rho_k < \eta_1 \\ x_k + d_k & \rho_k \geq \eta_1 \end{cases}$$

## 2. Desarrollo

En la actualidad, los fenómenos complejos son representados por medio de una función ruidosa:

$$f(x) = f_s(x) + \varepsilon_f(x) \quad (2)$$

donde  $\varepsilon(x)$  es un término de ruido, que es supuesto aleatorio.

### 2.1. Método de región de confianza para funciones con ruido

En este caso, debemos hacer adaptaciones al método de región de confianza. En primer lugar, debemos considerar que en caso de poder evaluar el gradiente de  $f_s$ , será con términos de ruido:

$$g(x) = g_s(x) + \varepsilon_g(x) \quad (3)$$

Además que para  $\Delta_k \ll 1$ , podemos tener que  $\rho_k$  sea dominado por el ruido. Por este motivo, [4] proponen la medida de confianza tolerante al ruido:

$$\rho_k = \frac{f(x_k + d_k) - f(x_k) - r\epsilon_f}{m_k(d_k) - m_k(0) - r\epsilon_f} \quad (4)$$

Donde  $\epsilon_f$  es una cota superior del ruido de  $f$ , es decir,  $|\varepsilon_f| \leq \epsilon_f$  y  $r = \frac{2}{1-\eta_2}$ .

### 2.2. Análisis de convergencia

A continuación se enlistan los supuestos bajo los cuales [4] muestra que el algoritmo de región de confianza para funciones con ruido genera una sucesión que visita infinitas veces una región crítica  $C_1$  dada por:

$$C_1 := \left\{ x : \left\| g(x) \right\| \leq (r+1)\epsilon_g + \frac{\beta}{2} \right\}$$

y que una vez que visitamos la región crítica  $C_1$ , no podemos alejarnos mucho de esta región:

1. El gradiente de la función objetivo  $g_s(x)$  es Lipschitz continua.
2. Los términos de error  $\varepsilon_f$  y  $\varepsilon_g$  están acotados:

$$|\varepsilon_f| \leq \epsilon_f \quad |\varepsilon_g| \leq \epsilon_g$$

3. Existe una constante  $L_B > 0$  tal que las matrices  $B_k$  satisfacen:

$$\|B_k\| < L_B, \forall k$$

4. El paso  $p_k$  es cuando menos tan bueno como el del punto de Cauchy:

$$m_k(0) - m_k(p_k) \geq m_k(0) - m_k(p_k^C) \geq \frac{1}{2} \|g_k\| \min \left\{ \Delta_k, \frac{\|g_k\|}{\|B_k\|} \right\}$$

5.  $f_s$  está acotada inferiormente.

### 2.3. Estimando la cota del ruido

Una vez que requerimos que el ruido de la función y su gradiente estén acotados, nos interesa estimar la cota  $\epsilon_f$  y  $\epsilon_g$ . Nos basamos en [2], evaluando  $f(x)$  en  $m$  puntos equiespaciados y tomando las diferencias:

$$\Delta^{k+1}f(t) = \Delta^k f(t+h) - \Delta^k f(t)$$

De forma que la varianza de la  $k$ -ésima diferencia es

$$\begin{aligned} \text{Var}(\Delta^k \epsilon_f(x)) &= \frac{\text{Var}(\epsilon_f)}{\gamma_k} \\ \gamma_k &= \frac{(k!)^2}{(2k)!} \end{aligned}$$

De forma que

$$(\gamma_k \mathbb{E}[(\Delta^k f(x))^2])^{1/2} \rightarrow \text{Var}(\epsilon_f) \quad (5)$$

cuando  $h = x_{i+1} - x_i \rightarrow 0$ .

Una vez que aproximamos la varianza de  $\epsilon_f$ , podemos aproximar  $\epsilon_f$  por la desigualdad de Chebyshev[5]:

$$\mathbb{P}\left(|\epsilon_f - \mathbb{E}[\epsilon_f]| \geq k\sqrt{\text{Var}(\epsilon_f)}\right) \leq \frac{1}{k^2}$$

### 2.4. Actualización por BFGS

El método BFGS actualiza de forma iterativa una aproximación de la matriz Hessiana  $B_k$ , en cada etapa del proceso de optimización.

La ecuación de actualización BFGS para la aproximación de la Hessiana es la siguiente:

$$B_{k+1} = B_k + \frac{\mathbf{y}_k \mathbf{y}_k^T}{\mathbf{y}_k^T \mathbf{s}_k} - \frac{B_k \mathbf{s}_k \mathbf{s}_k^T B_k^T}{\mathbf{s}_k^T B_k \mathbf{s}_k} \quad (6)$$

donde  $B_k$  es la aproximación actual de la matriz Hessiana,  $\mathbf{y}_k = \nabla f(x_{k+1}) - \nabla f(x_k)$  es la diferencia de gradientes entre dos iteraciones sucesivas,  $\mathbf{s}_k = x_{k+1} - x_k$  es la diferencia de posiciones entre dos iteraciones sucesivas. [3]

En el caso de la implementación de BFGS para el método de región de confianza, la actualización de  $\mathbf{s}_k$  va a ser la dirección  $d_k$  obtenida que minimiza el modelo (1), en este caso se toma la aproximación de Dogleg.

### 3. Algoritmo

El algoritmo ECNoise de [2] está dado por:

| <b>Algoritmo 1:</b> Algoritmo ECNoise. |   |
|--|---|
| <b>Entrada:</b> $f, x_0, m, h$         |   |
| <b>Salida:</b> $\hat{\epsilon}_f$      |   |
| 1                                      | <b>para</b> $i = 0$ <b>hasta</b> $m$ <b>hacer</b>                               |
| 2                                      | $T_i^0 \leftarrow f(x_0 + ih);$   |
| 3                                      | <b>fin</b>  |
| 4                                      | <b>para</b> $k = 0$ <b>hasta</b> $m - 1$ <b>hacer</b>                           |
| 5                                      | $\gamma_k \leftarrow \frac{(k!)^2}{(2k)!};$                                     |
| 6                                      | $\sigma_k \leftarrow \sqrt{\frac{\gamma_k}{m+1-k} \sum_{i=0}^{m-k} (T_i^k)^2};$ |
| 7                                      | <b>para</b> $i = 0$ <b>hasta</b> $m - k$ <b>hacer</b>                           |
| 8                                      | $T_i^{k+1} \leftarrow T_{i+1}^k - T_i^k;$                                       |
| 9                                      | <b>fin</b>  |
| 10                                     | <b>fin</b>  |

El algoritmo de región de confianza adaptado a funciones con ruido está dado por:

| <b>Algoritmo 2:</b> Algoritmo de Región de confianza para funciones con ruido con BFGS. |   |
|---|---|
| <b>Entrada:</b> $f, x_0, \epsilon_f$  |   |
| <b>Salida:</b> $x^*$  |   |
| 1   | $k \leftarrow 0;$   |
| 2   | $r \leftarrow 2/(1 - \eta_2);$  |
| 3   | <b>aproximar</b> por diferencias finitas $g_0 \approx \nabla f(x_0);$   |
| 4   | Inicializar $B_0 = \mathbb{I};$   |
| 5   | <b>mientras</b> $\ g_k\  > 0$ <b>hacer</b>  |
| 6   | <b>aproximar</b> $d_k$ , la solución de (1);  |
| 7   | <b>calcular</b> $\rho_k = \frac{f(x_k) - f(x_k + d_k) + r\epsilon_f}{m_k(0) - m_k(d_k) + r\epsilon_f};$       |
| 8   | <b>si</b> $\rho_k < \eta_1$ <b>entonces</b>   |
| 9   | $\Delta_{k+1} \leftarrow \lambda_1 \Delta_k$  |
| 10  | <b>en otro caso</b>   |
| 11  | $x_{k+1} \leftarrow x_k + d_k;$   |
| 12  | <b>Aproximar</b> por diferencias finitas $g_{k+1} \approx \nabla f(x_{k+1});$                                 |
| 13  | $y_k \leftarrow g_{k+1} - g_k;$   |
| 14  | $B_{k+1} \leftarrow B_k + \frac{y_k y_k^\top}{y_k^\top d_k} - \frac{B_k d_k d_k^\top B_k}{d_k^\top B_k d_k};$ |
| 15  | <b>si</b> $\rho_k > \eta_2$ <b>entonces</b> $\Delta_{k+1} \leftarrow \lambda_2 \Delta_k;$                     |
| 16  | <b>fin</b>  |
| 17  | $k \leftarrow k + 1;$   |
| 18  | <b>fin</b>  |

## 4. Resultados

Se modificó el algoritmo ECNoise disponible en el [sitio web de Stefan Wild](#) para trabajar en Julia y poder tomar como argumentos de entrada la función  $f$ , el punto  $x_0$ , el número de evaluaciones  $m$  y el tamaño de paso  $h$ , de forma que coincida con el pseudocódigo 1. De esta forma, se puede incorporar directamente en el algoritmo 2. Tomamos  $k = 10$  de forma que

$$\mathbb{P}(|\varepsilon_f - \mathbb{E}[\varepsilon_f]| \geq k\hat{\varepsilon}_f) \leq \frac{1}{k^2} = 0.01$$

Donde  $\hat{\varepsilon}_f$  es la aproximación del ruido obtenida por el algoritmo 1. Para aproximar el gradiente, se utiliza una diferencia centrada:

$$\frac{\partial f}{\partial x_i} f(x) \approx \frac{f(x + he_i) - f(x - he_i)}{2h}$$

A modo de prueba, tomamos la función de Rosenbrock para  $n = 2$  y  $n = 100$  más un ruido normal con media 0 y varianza  $10^{-4}$  y  $10^{-6}$  respectivamente, así como la función de Wood más un ruido uniforme  $(0, 10^{-5})$ . Como cota del gradiente, una vez que:

$$\frac{\partial f}{\partial x_i} f(x) = \frac{f_s(x + he_i) - f_s(x - he_i)}{2h} + \frac{\varepsilon_f(x + he_i) - \varepsilon_f(x - he_i)}{2h}$$

tenemos que  $(\epsilon_g(x))_i \approx \frac{k\epsilon_f}{\sqrt{2h}}$ , de forma que la desviación estándar de  $\|\epsilon_g(x)\|$  está acotada por  $\omega = \frac{\sqrt{n}\epsilon_f}{\sqrt{2h}}$ , y tomamos  $tol = 10^{-6} + \frac{\sqrt{n}\hat{\varepsilon}_f}{2h} = 10^{-6} + \frac{\omega}{\sqrt{2}}$  para la convergencia, con  $h = 10^{-3}$ , tomando en cuenta [1]. Los resultados se muestran en la tabla 1.

| Función              | Convergencia | Iteraciones | $\hat{\varepsilon}_f$    | $\epsilon_f$                         |
|----------------------|--------------|-------------|--------------------------|--------------------------------------|
| Rosenbrock $n = 2$   | Si           | 28          | $8.50747 \times 10^{-5}$ | $10^{-4}$                            |
| Rosenbrock $n = 100$ | Si           | 1627        | $1.32527 \times 10^{-6}$ | $10^{-6}$                            |
| Wood                 | Si           | 155         | $2.14961 \times 10^{-6}$ | $\frac{1}{2\sqrt{3}} \times 10^{-5}$ |

Cuadro 1: Resultados del algoritmo 2 para funciones con ruido aleatorio.

## Referencias

- [1] J. J. Moré and S. M. Wild, “Estimating derivatives of noisy simulations,” *ACM Transactions on Mathematical Software*, vol. 38, no. 3, pp. 1–21, Apr. 2012. [Online]. Available: <https://doi.org/10.1145/2168773.2168777>
- [2] J. J. Moré and S. M. Wild, “Estimating computational noise,” *SIAM Journal on Scientific Computing*, vol. 33, no. 3, pp. 1292–1314, Jan. 2011. [Online]. Available: <https://doi.org/10.1137/100786125>
- [3] J. Nocedal and S. Wright, *Numerical Optimization*, 2nd ed., ser. Springer Series in Operations Research and Financial Engineering. New York, NY: Springer, Jul. 2006.

- [4] S. Sun and J. Nocedal, “A trust region method for the optimization of noisy functions,” 2022. [Online]. Available: <https://arxiv.org/pdf/2201.00973.pdf>
- [5] L. Wasserman, *All of Statistics*. Springer New York, 2004. [Online]. Available: <https://doi.org/10.1007/978-0-387-21736-9>